Laporan Analisis Klasifikasi Credit Card Fraud

Penanganan Class Imbalance Menggunakan Metode Ensemble dan SMOTE

1. Pendahuluan

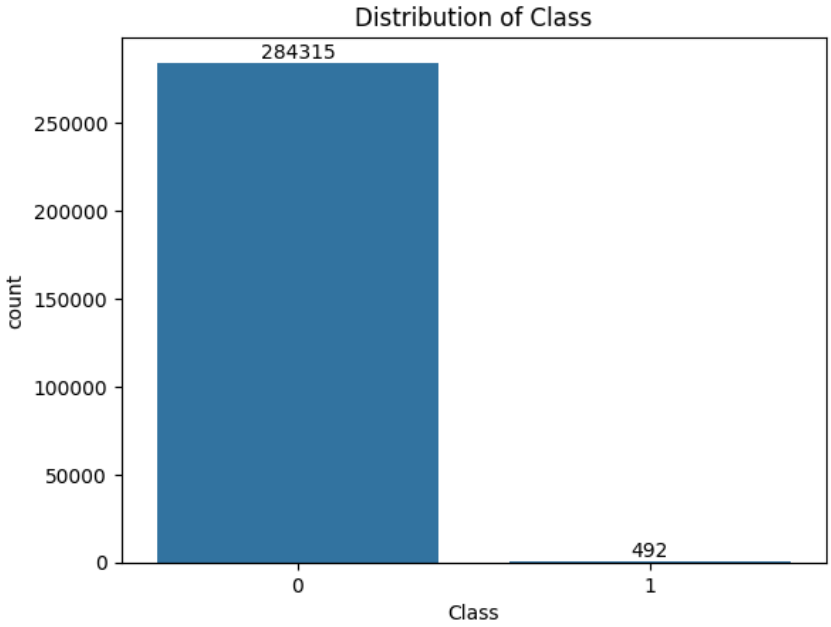
Deteksi penipuan kartu kredit (Credit Card Fraud Detection) merupakan salah satu masalah klasik dalam ranah **machine learning** yang memiliki tantangan utama berupa ketidakseimbangan kelas (**class imbalance**). Laporan ini merangkum hasil analisis data dan pemodelan klasifikasi menggunakan dataset `creditcard.csv` yang terdiri dari 284.807 baris dan 31 kolom observasi transaksi. Tujuan utama dari eksperimen ini adalah membandingkan performa model klasifikasi sebelum dan sesudah dilakukan penanganan ketidakseimbangan data menggunakan metode SMOTE (**Synthetic Minority Over-sampling Technique**).

2. Eksplorasi dan Distribusi Kelas Awal

Tahap pertama dalam analisis ini adalah memahami struktur data dan distribusi variabel target, yaitu atribut `Class` (0 untuk transaksi Normal, 1 untuk transaksi Fraud). Berdasarkan hasil eksplorasi data awal, dataset ini menunjukkan ketidakseimbangan yang sangat ekstrem. Dari total 284.807 transaksi, didapatkan hasil distribusi sebagai berikut:

- **Normal (0)**: 284.315 transaksi (99,83%)
- **Fraud (1)**: 492 transaksi (0,17%)

Rasio ketidakseimbangan antara kelas Normal dan Fraud adalah sekitar 577,9 : 1. Visualisasi dari distribusi awal ini dapat dilihat pada Gambar 1.



Gambar 1: Distribusi Kelas Awal (Normal vs Fraud)

Ketimpangan ini mengindikasikan bahwa model klasifikasi standar akan cenderung mendominasi prediksi ke arah kelas mayoritas (Normal) dan mengabaikan kelas minoritas (Fraud).

3. Pendekatan Penanganan Class Imbalance

Untuk menangani masalah ketidakseimbangan kelas tersebut, dataset terlebih dahulu dibagi menjadi data latih (**training set**) dan data uji (**testing set**) dengan perbandingan 80:20. Pembagian ini dilakukan dengan parameter `stratify=y` untuk memastikan proporsi kelas Fraud di data latih dan data uji tetap sama seperti proporsi aslinya.

Selanjutnya, pendekatan level data yang dipilih adalah **Oversampling** menggunakan metode **SMOTE**. Penting untuk dicatat bahwa **resampling** dengan SMOTE **hanya** diterapkan pada data latih. Data uji tetap dipertahankan pada distribusi aslinya agar dapat merefleksikan performa model pada dunia nyata.

Sebelum penerapan SMOTE pada data latih, jumlah kelas adalah:

- Kelas 0 (Normal) = 227.451 observasi
- Kelas 1 (Fraud) = 394 observasi

Setelah SMOTE diterapkan, metode ini mensintesis data baru untuk kelas minoritas sehingga jumlahnya seimbang dengan kelas mayoritas:

- Kelas 0 (Normal) = 227.451 observasi
- Kelas 1 (Fraud) = 227.451 observasi

Langkah praproses tambahan yang diterapkan adalah standardisasi menggunakan `StandardScaler` pada fitur `Time` dan `Amount` untuk menyamakan skala fitur sebelum dimasukkan ke dalam model.

4. Pemodelan Klasifikasi

Algoritma klasifikasi yang digunakan dalam analisis ini adalah metode ensemble **Random Forest** (`RandomForestClassifier`). Random Forest dipilih karena ketahanannya terhadap overfitting dan kemampuannya menangani pola non-linear pada data kompleks. Dua model dibangun untuk keperluan perbandingan:

1. **Model Base (Tanpa Resampling)**: Dilatih menggunakan data latih asli (imbalanced).
2. **Model SMOTE**: Dilatih menggunakan data latih yang telah diseimbangkan dengan SMOTE.

5. Performansi Model dan Analisis Perbandingan

5.1. Mengapa Accuracy Tidak Cukup?

Dalam kasus **fraud detection**, metrik **Accuracy** (akurasi) sangat menyesatkan. Berdasarkan distribusi kelas, sebuah model prediksi naif yang selalu menebak "Normal (0)" secara membabi buta akan mendapatkan akurasi sebesar 99,83%. Namun, model tersebut memiliki **Recall** 0% untuk kelas Fraud, yang berarti gagal total dalam mendeteksi penipuan. Oleh karena itu, metrik seperti **Precision**, **Recall**, **F1-Score**, dan **AUC-ROC** lebih diutamakan untuk mengukur keandalan model dalam menangkap kasus minoritas.

5.2. Hasil Evaluasi

Performa dari kedua model dievaluasi pada data uji (56.962 observasi) dan dirangkum dalam tabel berikut:

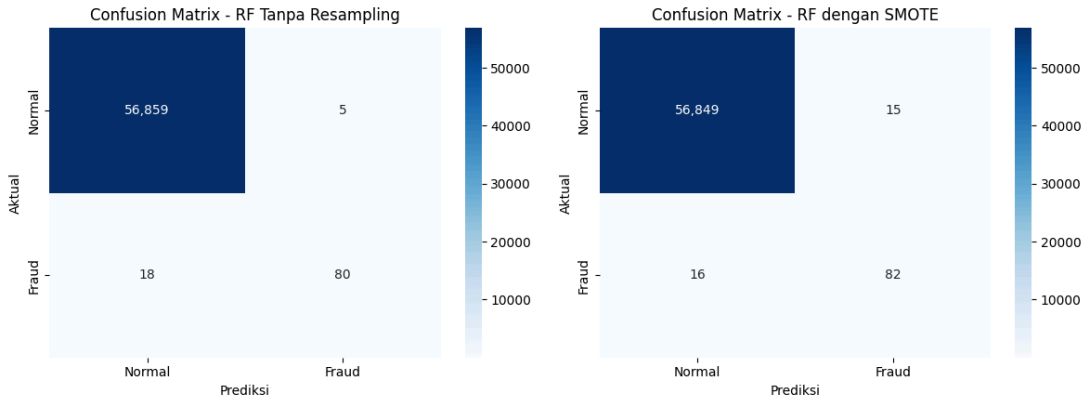
Model	Precision	Recall	F1-Score	AUC-ROC	Accuracy
RF Tanpa Resampling	0.9412	0.8163	0.8743	0.9630	0.9996
RF dengan SMOTE	0.8454	0.8367	0.8410	0.9731	0.9995

Tabel 1: Perbandingan Metrik Evaluasi Model

5.3. Analisis Perbandingan

Berdasarkan hasil metrik evaluasi di atas dan didukung oleh **Confusion Matrix** pada Gambar 2, kita dapat mengamati **trade-off** (pertukaran) kinerja akibat penerapan SMOTE:

1. **Peningkatan Recall (Sensitivitas)**: Model RF dengan SMOTE menunjukkan kenaikan nilai **Recall** untuk kelas fraud (dari 81,63% menjadi 83,67%). Hal ini berarti model SMOTE lebih sensitif dan berhasil mendeteksi lebih banyak transaksi fraud aktual yang sebelumnya lolos pada model tanpa resampling.
2. **Penurunan Precision**: Peningkatan daya deteksi ini mengorbankan metrik **Precision**, yang turun cukup signifikan dari 94,12% menjadi 84,54%. Ini menunjukkan bahwa model SMOTE menghasilkan lebih banyak **False Positives** (transaksi normal yang salah diprediksi sebagai fraud).
3. **Peningkatan AUC-ROC**: Metrik **AUC-ROC** mengalami kenaikan dari 0.9630 menjadi 0.9731. AUC mengukur kemampuan model dalam membedakan antara kelas positif dan negatif secara probabilitas. Kenaikan ini menegaskan bahwa secara keseluruhan, model yang dilatih dengan SMOTE memiliki daya pisah (**separability**) yang lebih baik di berbagai nilai ambang batas (**threshold**).



Gambar 2: Perbandingan Confusion Matrix: Model Tanpa Resampling vs Model SMOTE

6. Kesimpulan

Penggunaan SMOTE terbukti mampu meningkatkan kemampuan model (terlihat pada naiknya metrik **Recall** dan **AUC-ROC**) dalam mengenali transaksi **fraud**, yang merupakan prioritas utama dalam kasus bisnis perbankan atau kartu kredit. Secara praktis, menangkap penipu (Recall tinggi) umumnya dianggap jauh lebih berharga daripada biaya atau

ketidaknyamanan meninjau beberapa transaksi normal yang dicurigai (False Positive/ Precision menurun). Meskipun F1-Score pada model SMOTE sedikit lebih rendah akibat terkoreksinya Precision, keseimbangan probabilitas klasifikasinya menjadi lebih inklusif terhadap kelas minoritas.