Laporan Praproses Data

House Prices - Advanced Regression Techniques

Rayyan Binar Ramadhan

1 Pendahuluan

Praproses data merupakan tahap fundamental dalam *pipeline machine learning* karena kualitas data yang digunakan sangat menentukan performa model. Laporan ini mendokumentasikan seluruh rangkaian praproses yang dilakukan terhadap dataset *House Prices - Advanced Regression Techniques* (`train.csv`) yang berisi 1.460 baris dan 81 kolom. Dataset mencakup atribut properti residensial seperti luas tanah, kualitas bangunan, jumlah kamar, dan `SalePrice` sebagai variabel target.

Tujuan praproses ini adalah membersihkan data dari nilai hilang, menangani *outlier*, mengubah data kategorikal menjadi numerik, menstandarkan skala fitur, serta mereduksi dimensi agar data siap untuk pemodelan prediksi harga rumah.

2 Langkah-langkah Praproses

2.1 Memuat Dataset

Dataset dimuat menggunakan `pandas.read_csv()` dari file `train.csv`. Informasi awal dataset:

Jumlah baris	1.460
Jumlah kolom	81
Kolom numerik (`int64`/`float64`)	38
Kolom kategorikal (`str`)	43

2.2 Analisis Data Awal

Pemeriksaan awal dilakukan dengan `df.info()` dan `df.describe()` untuk memahami tipe data, distribusi statistik, dan mendeteksi nilai hilang. Ringkasan statistik fitur numerik utama:

Statistik	GrLivArea	TotalBsmtSF	GarageArea	LotArea	SalePrice
mean	1515,46	1057,43	472,98	10516,83	180921,20
std	525,48	438,71	213,80	9981,26	79442,50
min	334	0	0	1300	34900
50%	1464	991,5	480	9478,5	163000
max	5642	6110	1418	215245	755000

Tabel 1: Ringkasan statistik fitur numerik utama

2.3 Penanganan *Missing Values*

Hasil `df.isnull().sum()` menunjukkan *19 kolom* memiliki nilai hilang:

Kolom	Jumlah Missing	Persentase
PoolQC	1453	99,52%
MiscFeature	1406	96,30%
Alley	1369	93,77%
Fence	1179	80,75%
MasVnrType	872	59,73%
FireplaceQu	690	47,26%
LotFrontage	259	17,74%
GarageYrBlt	81	5,55%
GarageType	81	5,55%
GarageFinish	81	5,55%
GarageCond	81	5,55%
GarageQual	81	5,55%
BsmtExposure	38	2,60%
BsmtFinType2	38	2,60%
BsmtCond	37	2,53%
BsmtFinType1	37	2,53%
BsmtQual	37	2,53%
MasVnrArea	8	0,55%
Electrical	1	0,07%

Tabel 2: Daftar kolom dengan missing values

Penanganan dilakukan dengan dua strategi:

1. *Drop kolom* dengan persentase *missing* $> 50\%$: `Alley`, `MasVnrType`, `PoolQC`, `Fence`, dan `MiscFeature`. Jumlah kolom berkurang dari 81 menjadi 76 dengan bentuk data (1460, 76).
2. *Imputasi* untuk kolom tersisa:
   - Kolom kategorikal yang *missing*-nya bermakna "tidak ada" (`FireplaceQu`, `GarageType`, `GarageFinish`, `GarageQual`, `GarageCond`, `BsmtQual`, `BsmtCond`, `BsmtExposure`, `BsmtFinType1`, `BsmtFinType2`) diisi `"None"`.
   - Kolom kategorikal lain diisi *modus*.
   - Kolom numerik diisi *median*.

2.4 Analisis Korelasi terhadap `SalePrice`

Analisis korelasi digunakan untuk memahami hubungan linear fitur numerik dengan target. Berikut 15 fitur dengan korelasi tertinggi:

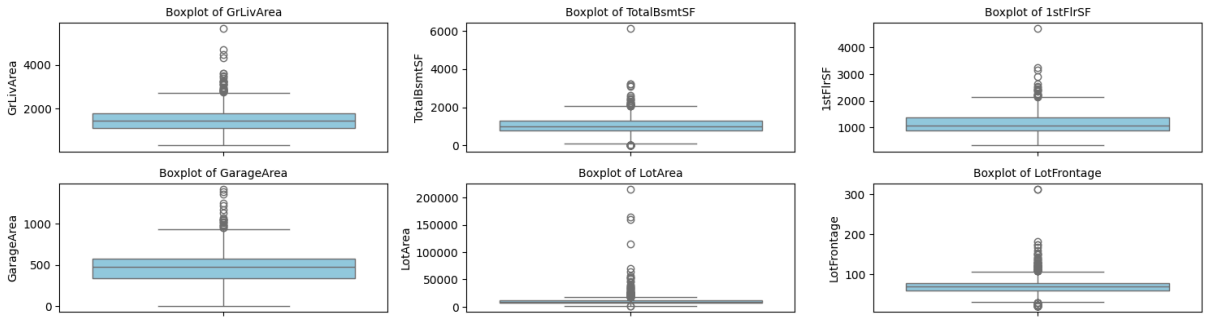
Fitur	Korelasi	Fitur	Korelasi
OverallQual	0,791	YearBuilt	0,523
GrLivArea	0,709	YearRemodAdd	0,507
GarageCars	0,640	MasVnrArea	0,473
GarageArea	0,623	Fireplaces	0,467
TotalBsmtSF	0,614	GarageYrBlt	0,467
1stFlrSF	0,606	BsmtFinSF1	0,386
FullBath	0,561	LotFrontage	0,335
TotRmsAbvGrd	0,534	WoodDeckSF	0,324

Tabel 3: Fitur dengan korelasi tertinggi terhadap SalePrice

Fitur `OverallQual` (kualitas keseluruhan) dan `GrLivArea` (luas bangunan) merupakan dua fitur paling berkorelasi dengan harga jual.

2.5 Deteksi dan Penanganan *Outlier*

Visualisasi *boxplot* digunakan untuk mendeteksi *outlier* pada fitur numerik utama:



Gambar 1: Boxplot fitur numerik sebelum penanganan outlier

Dari *boxplot* terlihat adanya *outlier* ekstrem pada `GrLivArea`, `LotArea`, `LotFrontage`, dan `TotalBsmtSF`. Penanganan dilakukan dua tahap:

1. *Filter domain-spesifik*: rumah dengan `GrLivArea > 4000` dan `SalePrice < 300000`, `LotFrontage > 300`, serta `LotArea > 100000`. Ditemukan **7 outlier** (indeks: 706, 934, 313, 523, 335, 1298, 249) sehingga bentuk data menjadi (1453, 76).
2. *Metode IQR* (1,5 × IQR) pada `TotalBsmtSF`, `1stFlrSF`, dan `GarageArea`:
   - `TotalBsmtSF` : 60 outlier
   - `1stFlrSF` : 7 outlier
   - `GarageArea` : 14 outlier

   Setelah tahap ini, bentuk data menjadi **(1371, 76)**.

Secara total, **89 baris** dihapus dari dataset.

2.6 Pemisahan Data Latih dan Uji

Dataset dibagi dengan rasio 80:20 menggunakan `train_test_split` (`random_state=42`):

Data	Jumlah Baris	Jumlah Kolom
X_train	1096	75
X_test	275	75

2.7 *Encoding* dan Standardisasi

Fitur dikelompokkan menjadi:

- *Numerik*: 37 fitur
- *Kategorikal*: 38 fitur

Transformasi dilakukan dengan `ColumnTransformer`:

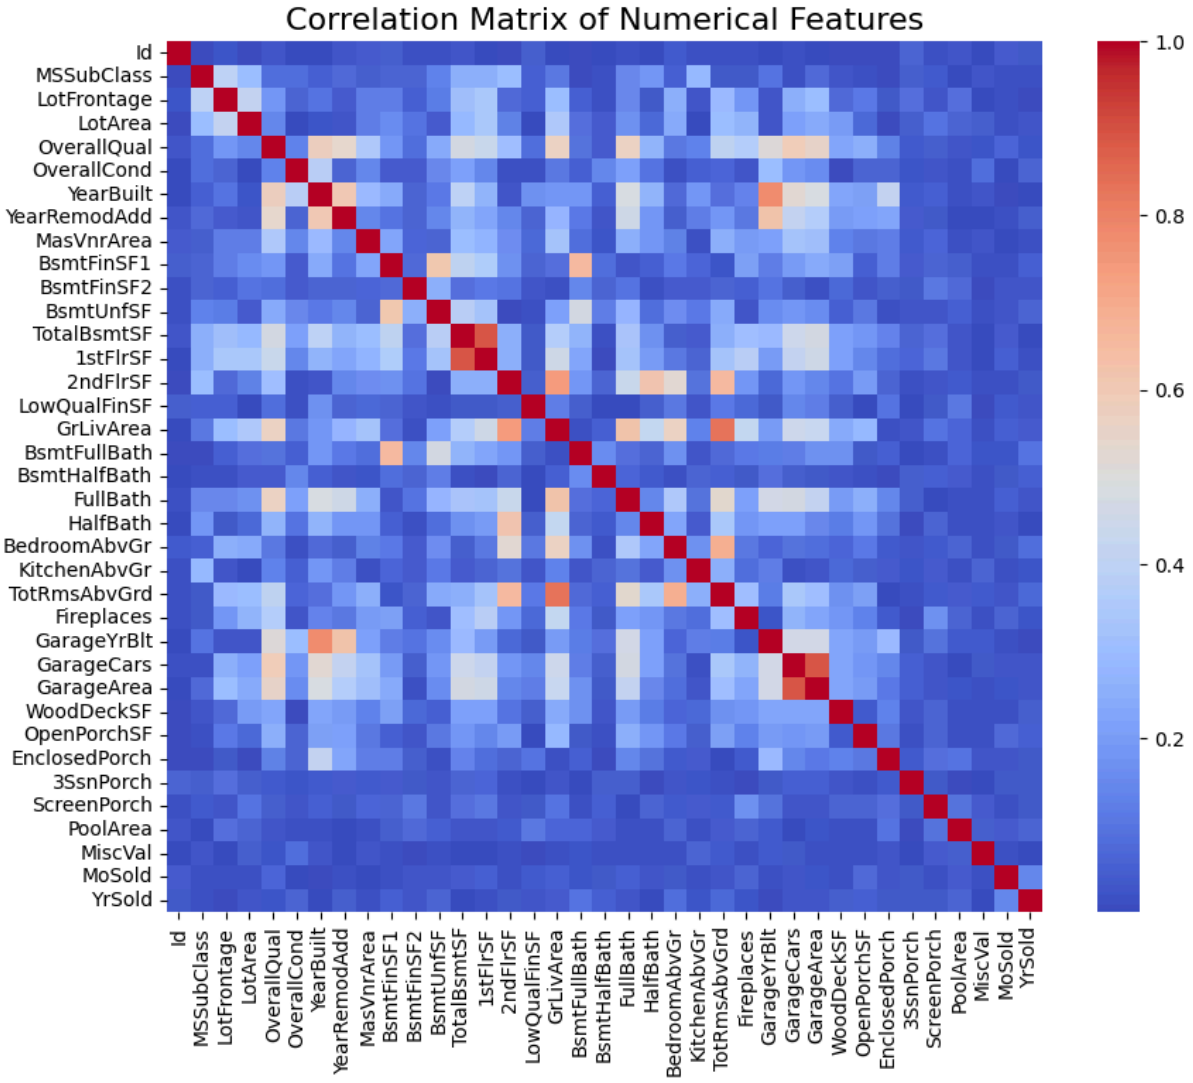
- `StandardScaler` untuk menstandarkan fitur numerik (mean = 0, std = 1).
- `OneHotEncoder(handle_unknown='ignore')` untuk mengubah fitur kategorikal menjadi vektor *one-hot*.

Hasil transformasi:

Dataset	Bentuk Setelah Transformasi
X_train	(1096, 263)
X_test	(275, 263)

2.8 Penanganan Multikolinearitas

Matriks korelasi antar fitur numerik divisualisasikan untuk mendeteksi multikolinearitas:



Gambar 2: Heatmap korelasi antar fitur numerik

Fitur dengan korelasi $> 0{,}85$ dihapus untuk menghindari redundansi. Dua fitur teridentifikasi: **`1stFlrSF`** dan **`GarageArea`** (masing-masing berkorelasi tinggi dengan `TotalBsmtSF` dan `GarageCars`). Setelah penghapusan, bentuk `X_train` menjadi (1096, 261).

2.9 *Principal Component Analysis* (PCA)

PCA diterapkan untuk mereduksi dimensi dan menangani multikolinearitas sisa. Sebelum PCA, dilakukan imputasi ulang dengan `SimpleImputer(strategy='median')` untuk memastikan tidak ada nilai hilang.

PCA dengan `n_components=0.95` (mempertahankan 95% varians) menghasilkan:

Tahap	**Jumlah Fitur**
Sebelum PCA	261
Setelah PCA (95% varians)	71

3 Ringkasan Dataset Akhir

Setelah seluruh tahapan praproses, dataset akhir memiliki karakteristik:

Aspek	**Nilai**
Jumlah data latih	1.096 baris
Jumlah data uji	275 baris
Jumlah fitur asli	81 kolom
Jumlah fitur setelah pembersihan	76 kolom
Jumlah fitur setelah *encoding*	263 kolom
Jumlah fitur setelah korelasi	261 kolom
Jumlah komponen PCA final	71 komponen
Target	SalePrice (kontinu)
Rentang target	34.900 – 755.000

Tabel 4: Ringkasan dataset akhir

Data akhir direpresentasikan sebagai `X_train_final` dan `X_test_final` dengan kolom `PC1` hingga `PC71`, siap digunakan untuk pelatihan model regresi.

4 Kesimpulan

Praproses data pada dataset House Prices - Advanced Regression Techniques berhasil dilakukan melalui rangkaian tahapan berikut:

1. *Pembersihan data*: penghapusan 5 kolom dengan *missing values* ekstrem dan imputasi strategis pada kolom lain.
2. *Penanganan outlier*: penghapusan 89 baris menggunakan pendekatan domain-spesifik dan IQR.
3. *Transformasi fitur*: standardisasi numerik dan *one-hot encoding* kategorikal $\rightarrow$ 263 fitur.
4. *Reduksi dimensi*: penghapusan 2 fitur berkorelasi tinggi dan PCA $\rightarrow$ 261 fitur menjadi 71 komponen utama.

Dataset akhir berisi **1.096 data latih** dan **275 data uji** dengan **71 komponen utama** yang mempertahankan **95% varians** data asli. Reduksi dari 81 kolom menjadi 71 komponen memungkinkan model dilatih lebih efisien tanpa kehilangan informasi signifikan.