Laporan Praktikum: Analisis Data

Eksplorasi dan Analisis Dataset Buku Goodreads

1. Pendahuluan

Laporan ini menguraikan langkah-langkah eksplorasi dan analisis data (EDA) yang dilakukan terhadap dataset buku Goodreads. Dataset ini diperoleh melalui proses **web scraping** dari halaman web Goodreads (**Best Books Ever**) sebanyak 16 halaman. Tujuan dari praktikum ini adalah untuk memahami karakteristik data, menganalisis statistik deskriptif, menangani nilai kosong serta **outlier**, dan menyajikan visualisasi data yang informatif.

2. Deskripsi Dataset

Dataset ini terdiri dari 1.600 baris data buku. Atribut utama yang terkandung di dalam dataset ini meliputi:

- **Judul**: Nama atau judul buku beserta informasi seri (tipe data **string**).
- **Penulis**: Nama pengarang atau penulis buku (tipe data **string**).
- **Rating**: Nilai rata-rata rating buku, berkisar antara 3.01 hingga 4.81 (tipe data **float64**).
- **Jumlah_Review**: Total ulasan atau **review** yang diberikan oleh pembaca (tipe data **int64**).
- **Skor**: Skor atau bobot buku dalam daftar rekomendasi (tipe data **int64**).

3. Statistik Deskriptif

Berdasarkan hasil perhitungan pada atribut numerik (`Rating`, `Jumlah_Review`, dan `Skor`), diperoleh ringkasan statistik sebagai berikut:

- **Rating**: Memiliki nilai rata-rata (**mean**) sebesar 4.10 dengan standar deviasi 0.24, nilai minimum 3.01, dan maksimum 4.81.
- **Jumlah_Review**: Memiliki rata-rata sebesar 554,677.19 ulasan dengan standar deviasi sebesar 971,723.74, serta rentang dari 106 hingga 11,842,854 ulasan.
- **Skor**: Memiliki rata-rata 59.96 dengan median 13.00, serta nilai maksimum mencapai 988.00.

Selain itu, analisis frekuensi pada atribut kategorikal menunjukkan dominasi kemunculan penulis tertentu seperti **Stephen King** (22 kemunculan) dan **Sarah J. Maas** (20 kemunculan).

4. Penanganan Data (Missing Value & Outlier)

Praproses data difokuskan pada pengecekan nilai kosong dan identifikasi nilai ekstrem.

4.1. Pengecekan Missing Value

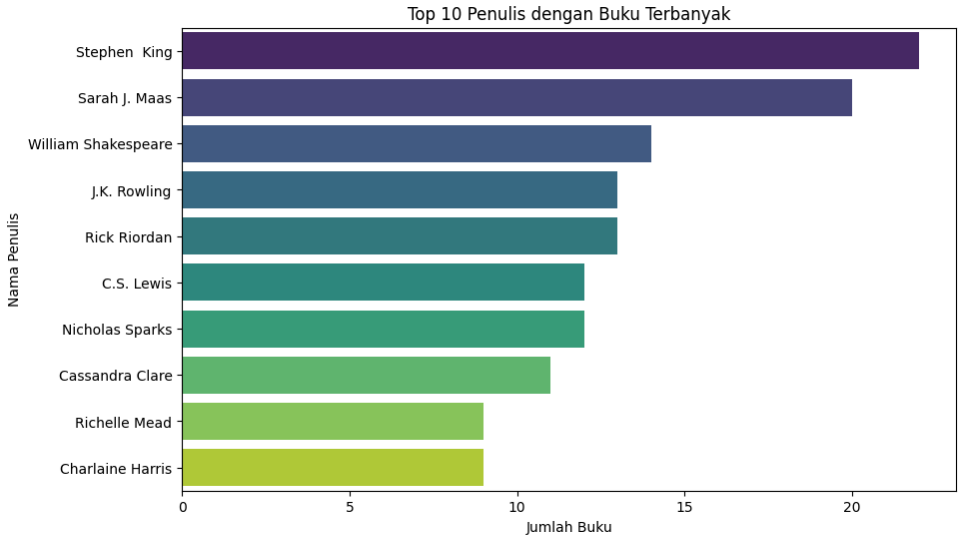
Pengecekan menggunakan `df.isna().sum()` menunjukkan bahwa tidak terdapat nilai yang hilang (**missing value**) pada seluruh kolom dataset (0 nilai kosong untuk setiap atribut). Oleh karena itu, tidak diperlukan proses imputasi data.

4.2. Deteksi dan Penanganan Outlier

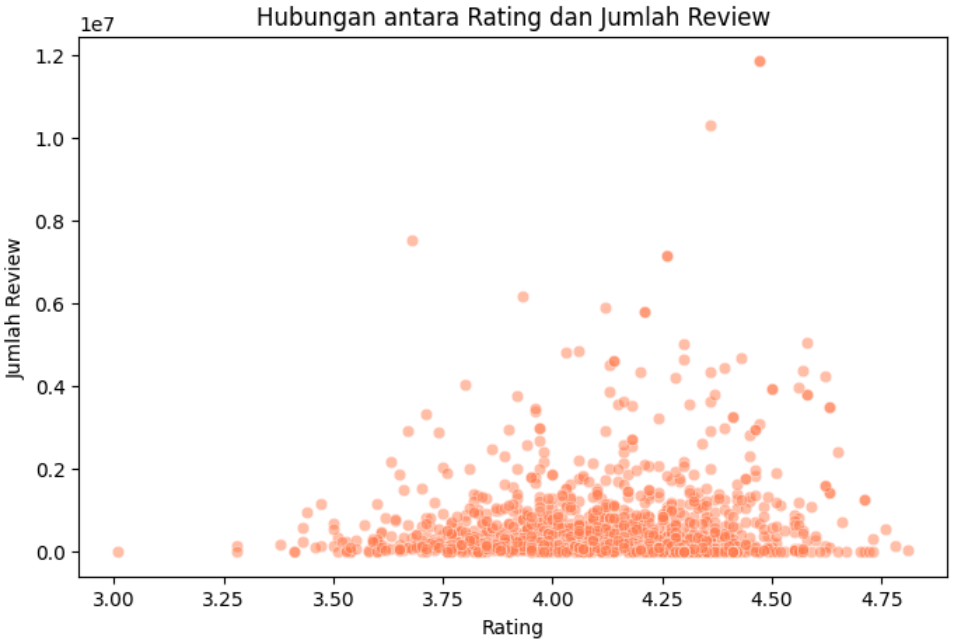
Identifikasi **outlier** menggunakan metode Interquartile Range (IQR) mendeteksi adanya **outlier** pada kolom **Rating** (15 data), **Jumlah_Review** (159 data), dan **Skor** (218 data). Namun, karena dataset ini bersumber dari daftar buku terbaik sepanjang masa (**Best Books Ever**), nilai-nilai tersebut merupakan nilai yang valid (**true values**) dan mencerminkan fenomena popularitas nyata, sehingga dipertahankan.

5. Visualisasi & Interpretasi Data

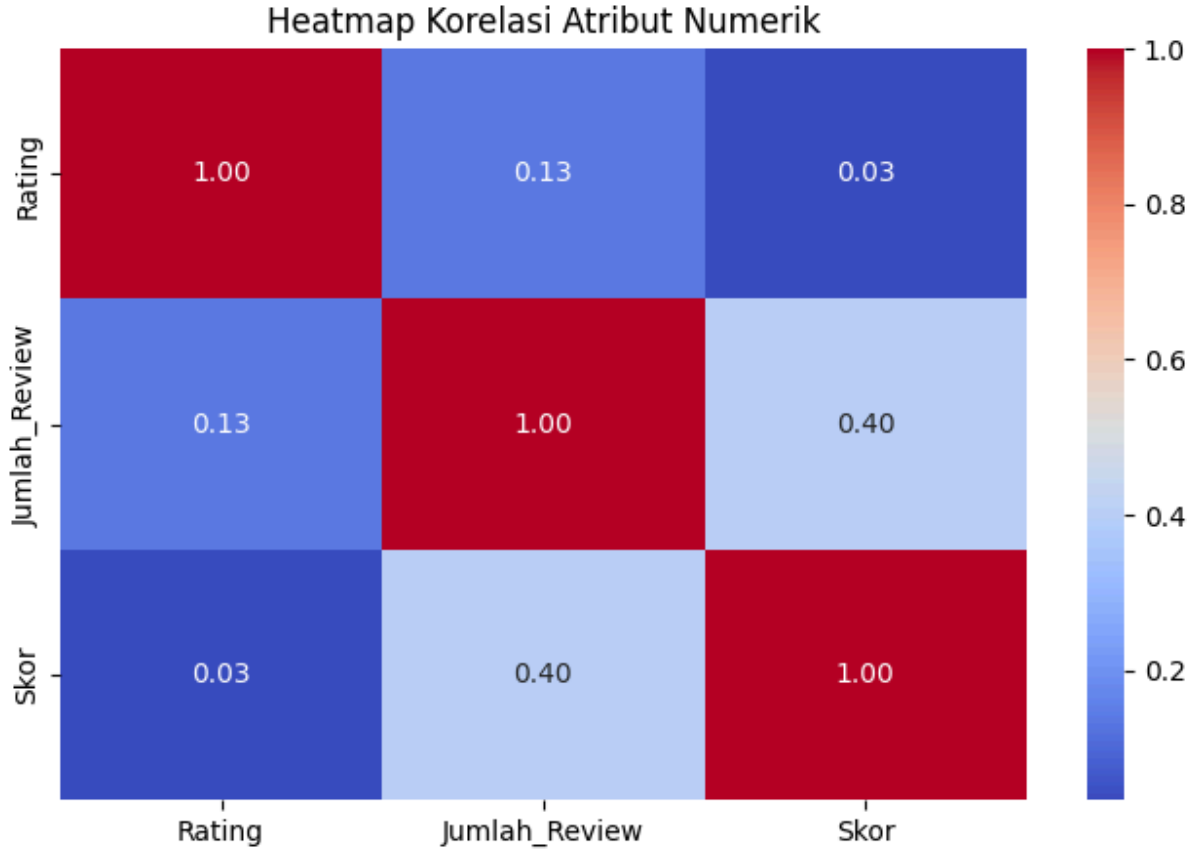
Data yang telah dibersihkan kemudian divisualisasikan untuk mendapatkan wawasan lebih mendalam terkait pola distribusi dan hubungan antar variabel.



Gambar 1: Distribusi Rating Buku dan Top 10 Penulis



Gambar 2: Hubungan antara Rating dan Jumlah Review



Gambar 3: Heatmap Korelasi Atribut Numerik

Berdasarkan hasil visualisasi data di atas:

- **Distribusi Rating Buku**: Grafik histogram dengan kurva KDE menunjukkan bahwa sebaran rating buku terkonsentrasi di kisaran 4.0 hingga 4.5, mengindikasikan kualitas dan apresiasi pembaca yang sangat tinggi.
- **Top 10 Penulis**: **Bar chart** memperlihatkan penulis dengan jumlah kemunculan terbanyak, didominasi oleh penulis fiksi, fantasi, dan horor populer.
- **Hubungan Rating dan Jumlah Review**: **Scatter plot** (dengan warna koral) menunjukkan bahwa buku dengan ulasan terbanyak tidak selalu memiliki rating mutlak tertinggi, namun seluruh buku mempertahankan standar rating minimum di atas 3.0.
- **Heatmap Korelasi**: Matriks korelasi antar atribut numerik memberikan gambaran mengenai pola hubungan linear antar variabel dalam dataset.

6. Kesimpulan

Analisis eksploratif terhadap dataset Goodreads (**Best Books Ever**) yang mencakup 1.600 buku dari 16 halaman web menunjukkan bahwa dataset bersih dari **missing values**. Meskipun terdeteksi adanya **outlier** pada beberapa kolom metrik popularitas dan rating, nilai tersebut dipertahankan karena merepresentasikan data valid yang mencerminkan popularitas nyata buku-buku terbaik. Visualisasi yang dihasilkan berhasil memberikan wawasan komprehensif mengenai sebaran rating, popularitas penulis, hubungan antara rating dan jumlah **review**, serta korelasi antar atribut numerik dalam dataset.